

東北大學



NORTHEASTERN
UNIVERSITY

毕业设计（论文）

GRADUATION DESIGN (THESIS)

论文题目 基于数字孪生的工业生产过程产品
质量性能预报

学院名称 信息科学与工程学院

专业名称 自动化

学生姓名 付蔚

指导教师 刘畅 讲师

二〇二五年 六月

东北大学本科毕业论文

基于数字孪生的工业生产过程产品质量性能 预报

学 院 名 称 ： 信息科学与工程学院

专 业 名 称 ： 自动化

学 生 姓 名 ： 付蔚

指 导 教 师 ： 刘畅 讲师

二〇二五年六月

Product Quality Performance Prediction based on Digital Twins in Industrial Production Process

by Fu Wei

Supervisor: Lecturer

Liu Chang

Northeastern University

June 2025

郑重声明

本人呈交的学位论文，是在导师的指导下，独立进行研究工作所取得的成果，所有数据、图片资料真实可靠。尽我所知，除文中已经注明引用的内容外，本学位论文的研究成果不包含他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确的方式标明。本学位论文的知识产权归属于培养单位。

本人签名：付蔚

日期：2025 年 6 月

摘 要

在现代钢铁生产过程中，针对冷轧连退带钢的力学性能预测是保证产品质量和工艺优化的重要措施，但由于其涉及到大量的工艺因素以及材料成分，传统的物理机理模型难以兼顾其非线性、高维度的工艺数据，不能达到高精度的预测效果，本文针对“带钢力学性能精准预测”的问题，提出一种机理-数据融合建模方法，并集成智能优化算法与数字孪生技术来使该模型得以应用于实际生产中，实现冷轧连退带钢力学性能预测结果的可视化。

首先根据热力学和动力学建立了经验公式机理模型，来模拟晶粒尺寸（CD）、碳当量（ C_{eq} ）、活化能（ Q ）等中间物理量；其次选用了 XGBoost、CatBoost、TabNet 等结构化的数据建模算法建立回归预测模型，并将机理模型产生的中间变量作为特征输入，实现物理模型和数据驱动模型的融合建模；然后引入了遗传算法（GA）、粒子群优化算法（PSO）及贝叶斯优化算法（Bayesian Optimization Algorithm, BO），优化特征选择及超参数配置；最后基于某钢厂采集的实际冷轧连退带钢生产数据集进行模型训练和预测性能评估。所构建的预测模型在抗拉强度（TS）和屈服强度（YS）两项性能指标上的预测取得 $R^2 > 0.95$ 的精度指标，在延伸率（EL）的预测精度 $R^2 > 0.90$ ，整体性能良好，优化后的模型较传统单一的数据驱动模型有了更佳的泛化性和稳定性。

最后，本文基于 Unity 平台开发了数字孪生仿真实现方式，在交互式用户界面上实时显示工艺参数、化学成分及力学性能的预测结果，可应用于钢铁工业企业内的生产过程监控以及智能辅助决策中，同时验证了上述算法模型的工程可行性和正确性，可以为钢铁工业智能制造提供参考依据。

关键词：连退过程；机理建模；机器学习；进化算法；数字孪生

ABSTRACT

In modern steel manufacturing, predicting the mechanical properties of strip steel in the continuous annealing process constitutes a critical measure for ensuring product quality and process optimization. However, due to the high-dimensional coupling of numerous process parameters and material compositions, traditional physics-based models struggle to handle the nonlinear and high-dimensional process data, thereby failing to achieve high-precision predictions. Addressing the challenge of "precise mechanical property prediction for continuous annealing strip steel," this thesis proposes a mechanism-data fusion modeling methodology that integrates intelligent optimization algorithms with digital twin technology, enabling practical industrial implementation while achieving visualization of prediction results for strip steel mechanical properties in the continuous annealing process.

In terms of algorithm design, an empirical formula-based mechanism model is first constructed based on thermodynamic and kinetic principles to simulate intermediate physical variables such as grain size (CD) the algorithm design process, and the first to create an empirical formula-based mechanism model that uses the following chemicals: carbon equivalent (Ceq), activation energy(Q), and grain size(CD) thermodynamic and kinetic fundamentals for simulating the intermediate physical variables of the process (DSM).After that, different organized data modeling algorithms (e. g., XGBoost, CatBoost, and TabNet, with the intermediate variables created by the mechanism model acting as input features, are used to build regression prediction models with the intermediary variables created from the mechanism model and achieve a combination of both. In order to optimize feature selection and hyperparameter configuration and even increase model performance, evolutionary algorithms, such as the Genetic Algorithm (GA), particle swarm optimization (PSO), Bayesian Optimization (BO), are also used to improve the model performance.

The developed predictive model demonstrates $R^2 > 0.95$ performance metrics for tensile strength (TS) and yield strength (YS) predictions, with elongation (EL) prediction accuracy exceeding $R^2 > 0.90$, exhibiting superior generalization capability and stability compared to conventional single-source data-driven models. In terms of prediction stability and generalization ability, the optimized model also shows good robustness.

Finally, a digital twin simulation system is developed on the Unity platform, with an interactive user interface that enables real-time display of process parameters, chemical compositions, and mechanical property prediction results. This system supports process monitoring and intelligent decision-making in industrial scenarios. The system validates the engineering feasibility of the proposed model and provides important technical support for smart manufacturing in the steel industry.

Keywords: Continuous annealing process; Mechanism modeling; Machine learning; Evolutionary algorithms; Digital twin

目 录

摘 要.....I

ABSTRACT..... III

1 绪论..... 1

 1.1 研究背景与意义 2

 1.2 国内外研究现状 2

 1.2.1 冷轧带钢力学性能预测研究现状 2

 1.2.2 数字孪生技术在钢铁生产中的应用研究 2

 1.3 相关技术概述..... 4

 1.3.1 结构化数据建模 4

 1.3.2 智能优化算法 6

 1.3.3 数字孪生技术 7

 1.4 论文内容及组织结构 8

2 冷轧带钢连退生产工艺机理解析..... 11

 2.1 引言 11

 2.2 冷轧连退带钢的力学性能影响因素 11

 2.2.1 化学成分 11

 2.2.2 晶粒尺寸 11

 2.2.3 冷轧与退火工艺条件 12

 2.2.4 应变速率效应 12

 2.2.5 其他因素 12

 2.3 冷轧过程中间变量 12

 2.3.1 晶粒尺寸（CD）模型..... 12

 2.3.2 碳当量（Ceq、Pem）模型..... 13

 2.3.3 活化能（Q）模型 14

 2.4 本章小结 14

3 基于机理模型的冷轧带钢质量力学性能预测..... 15

3.1 建模思路与整体框架	15
3.2 数据来源	16
3.3 特征选取与字段清洗	16
3.4 关键机理特征构造	16
3.5 建模方法简介	16
3.6 模型训练与结果分析	16
3.6.1 数据集划分与模型训练	16
3.6.2 模型对比分析	17
3.7 机理模型性能预测	18
3.8 本章小结	19
4 基于机理与数据融合的冷轧带钢质量力学性能预测.....	21
4.1 数据预处理与特征工程	21
4.1.1 数据清洗与缺失值处理	22
4.1.2 特征归一化与选择	22
4.2 模型结构与输入特征设计	23
4.2.1 输入特征设计	23
4.2.2 多输出进化学习模型	24
4.2.3 进化学习优化方法	24
4.3 模型训练与评估方法	24
4.3.1 参数设置	26
4.3.2 多输出回归策略与评估指标	26
4.3.3 模型评估指标	26
4.4 模型对比与分析	27
4.5 模型优化及性能提升	28
4.5.1 特征选择优化	28
4.5.2 超参数优化方法	29
4.5.3 优化效果评估与可视化	31
4.6 本章小结	32
5 数字孪生系统设计与实现.....	35

5.1 系统架构设计 35

 5.1.1 数据采集层 35

 5.1.2 数据传输层 36

 5.1.3 数据处理与分析层 36

 5.1.4 可视化与控制层 36

5.2 Unity 平台开发流程 36

5.3 功能展示与使用场景 37

5.4 本章小结 39

6 总结与展望 41

 6.1 本文工作总结 41

 6.2 未来研究展望 41

参考文献 43

致谢 49

1 绪论

1.1 研究背景与意义

近几年，钢铁行业的钢铁产量已经达到了饱和状态，但是对冷轧连退带钢产品的质量控制还有很大难度，特别是缺乏可以进行准确预报的质量预报模型，这也是造成冷轧连退带钢产品品质不稳定的主要因素^[1]。冷轧连退带钢作为一种重要基础材料被广泛应用到建筑、汽车、航空航天等一些比较先进的领域^[2]，但是这些领域的精密程度高，对于材料的质量都有着极其严格的要求，所以保证冷轧带钢产品的质量以及提高产品的性能的一致性，则是钢铁企业提升竞争力、降低自己的成本及资源消耗的关键所在。

以前的冷轧产品质检大都采取人工经验检验和人工调整的办法，无法对变化较多、较为复杂的生产过程做出有效的反应，达不到对质量预测准确性和及时性的需求^[3]。然而，随着智能制造与数字化的发展，数字孪生作为工业领域新的技术应用手段正被逐渐推广使用。数字孪生是在真实生产系统的基础上，利用智能制造相关技术和数字化方法，针对真实系统在虚拟空间内构建一个完整的物理实体的数字化模型，可以实时采集、模拟真实系统运行时的各种信息和状态的变化，以更好地实现产品质量性能预报的目的^[4]。

在冷轧连退带钢生产过程中，数字孪生技术可实现从冷连轧加热炉出口到冷连退拉矫机机组出入口间的每个位置或任意时间点上的实时监测，随时掌握诸如温度、压力、速度等工艺参数的变化^[5]，还可根据生产模型、虚实互动仿真、机理分析等方式预测材料在轧制过程中发生的微观组织变化，并根据以上因素的综合影响实现生产前后产品的实时质量预测，以保证产品生产后能达到设计预期目标^[6]。相较于传统方法而言，数字孪生技术更具有灵活性和精确性，能根据实时情况进行在线监控，并针对两者间的差异通过虚实互动调节进行快速修正反应，避免产品质量出现问题。

在钢铁行业，数字孪生的应用并不仅仅局限在质量上，在钢铁行业的数字孪生可与物联网、人工智能等结合，在系统中实现决策支持，实现智能化；并且可根据大量历史数据及实时数据通过数字孪生系统，借助机器学习以及深度学习等方法进行优化，得到更加准确的质量预测模型，产品质量的预报更加准确^[5]。基于数字孪生的生产决策支持系统可以帮助提高生产效率、减少人工干预、节约成本、节省能源资源，助力

钢铁企业走向智能的道路。

数字孪生对冷轧连退带钢生产工艺质量和质量控制有积极影响，利用数字孪生技术能够实现实时的质量预报，通过对历史数据的精准计算分析以及预测，能够帮助企业对生产过程存在的隐患问题进行预测，在此之前，根据出现的问题采取预防措施，及时进行生产调整。利用数字孪生技术建立一种基于数字孪生的智能化质量预测方法可以在生产环节中针对钢铁生产中的问题实施精准化、自动化的质量管理，使产品质量更加稳定，进而提高我国钢铁企业的产品质量，促进国内钢铁企业的市场竞争力^[7]。

因此，本文的主要目的就是建立精准度较高且具有可部署性的质量预报模型，采用数字孪生的思路来建立冷轧连退带钢产品质量性能的预测模型，使产品质量具有很好的经济效益，在推动钢铁行业数字化转型，提高生产效率以及实现绿色发展上都有着重大的理论意义和实践价值。

1.2 国内外研究现状

1.2.1 冷轧带钢质量力学性能预测研究现状

物理机理模型基于热力学或动力学等原理来描述工业生产过程中出现的物理现象的变化，并被广泛应用到钢铁行业中，比如用于模拟冷轧过程中产生的材料变形、晶粒大小及力学性能的模型。但是传统的物理机理模型大都是以固定假设条件以及实验数据为基础建立起来的，对于一些变化较大的生产环境不能准确反映生产过程中参数对质量的影响。另外 Wang 等人^[8]发现，物理机理模型对于高频变化的实时数据没有足够高的灵活性与适应性，不足以应对复杂的工业生产制造情况。

其中，近 10 多年来，人们主要应用机器学习方法实现钢铁行业产品的质量预测。通过机器学习的预测方法可从海量的历史生产数据中获取非线性关系，并且具有良好的鲁棒性和预测能力；Zhang 等^[9]采用支持向量机（SVM）、随机森林（RF）和 XGBoost 等方法对冷轧带钢力学性能进行预测，其预测精度较高；基于数据驱动的数据模型可通过历史数据预测出钢材的质量水平，并降低人为因素的影响。但是，在使用机器学习方法时也会存在不足之处。大部分现有的研究都只用到了数据驱动的方法来完成预测，并没有考虑到实际生产中的物理规律，因此，对于生产的人员无法提供一些更具体的指导意义；同时由于大部分机器学习方法都需要大量的数据来训练，这就会使成本变得很高，且在少量样本或者出现特殊情况下的预测会比较差。

1.2.2 数字孪生技术在钢铁生产中的应用研究

数字孪生是一种依托实时的数据采集、仿真实现及模型优化的新一代技术，在制造业领域已有大量的应用探索。数字孪生技术基于虚体对实体的实时监测、模仿，可以为生产过程提供指导优化决策。Zhao 等^[10]基于数字孪生技术，提出基于数字孪生进行实时监控预测的方法，采用物理过程和虚拟仿真系统相结合的方式，在一定程度上实现了对生产的精细化控制，能够针对生产过程问题及时调整生产参数来保证产品质量；但也需要注意的是，数字孪生技术应用到钢铁行业尚属起步阶段，虽然数字孪生可以模拟复杂的物理现象，但是受限于设备的信息传感精度及数据采集速度，其实时反馈及精确预测仍具有一定的局限性，这就需要在保证了设备运行稳定性及数据实时性的基础上，能最大程度地对数字孪生技术进行合理的应用。Xu 等人^[11]认为如何把数字孪生技术和机器学习结合起来，利用大数据提高预测精度，是目前该方面的研究难点，也是面临的又一问题。综上所述，数字孪生技术的集成优化在工业应用上仍然还存在很多问题与困难。

结合物理机理模型与机器学习的混合模型是近些年的一个研究热点。许多学者在建立机理模型的基础上引入数据驱动模型，希望利用物理模型的解释性和机器学习模型的预测优势^[12]。Zhang 等人^[9]采用物理机理模型所生成的晶粒尺寸、位错密度等中间变量作为机器学习模型的输入特征，从而使得建立起来的混合模型对于复杂的工艺变化具有较好的适应性。而以上这些混合模型也一定意义上地规避了单一模型的不足，并提高了预测精度。但由于目前针对上述混合模型的研究并不多，因此仍存在一些亟待解决的问题，如何有效地把机理模型和机器学习模型结合起来，如何合理地选取中间变量以及怎样保证模型的准确性与稳定性都还是需要进一步研究的内容^[13]。

此外，由于不同模型的应用面较窄且少有成熟模型存在，因此如何将其应用于实际场景下，使模型适用于较为复杂的工业环境，并具有较好的实时性等问题有待解决；针对国内外冷轧连退带钢质量预测及优化的研究已有了一定的成果^[14]，但是当前还面临着很多问题：第一种是传统的机理模型不易于对复杂的工业过程进行建模；第二种是机器学习方式的建模无法给予用户足够的可解释性；第三种则是数字孪生技术虽然在实时监控、预测等方面具有巨大的优势^[15]，但在钢铁行业中的实际运用仍然存在一些技术障碍，混合模型的建模需要考虑如何将机理模型与数据驱动模型相结合的问题。

综上所述，现有的各个方法各有利弊，难以兼顾高精度预报和物理解释，所以本

文在此基础上提出一种数据—物理融合建模方法，采用不同优化及可视化等方法使模型更具有可操作性和解释性。

1.3 相关技术概述

1.3.1 结构化数据

（1）XGBoost

XGBoost (Extreme Gradient Boosting) 是基于梯度提升树 (Gradient Boosting Trees, GBT) 框架的一种强大的集成学习算法，常见于机器学习的各种任务当中。作为一种高效的实现方式，相比于一般的梯度提升算法来说，能够处理更大规模的数据集，并且可以做到更快地计算以及更低的内存开销^[16]。在这一点上，它从已有模型的基础之上，逐渐加入更多的弱学习器（一般为决策树），来逐步减小模型预测误差，在此之上又增加了正则化项（包括 L1 和 L2 正则化），以此解决了之前的梯度提升树容易出现过拟合的问题，并且在一定程度上也有利于之后的泛化性能。

使用增量式训练，可以对每次添加的新树进行加权，进而得到更好的预测结果；XGBoost 的实现可以并行化执行，在算法层面能做到很好的自动化处理特征，速度快且适应大数据集及缺失值；XGBoost 支持多种损失函数，因而更能满足多目标的优化问题^[17]。XGBoost 还具有交叉验证、模型调优与超参数搜索的功能（如：贝叶斯优化法、网格搜索法等），使模型达到最优状态，提高模型预测精准度^[18]。

（2）CatBoost

CatBoost (Categorical Boosting) 是 Yandex 公司基于梯度提升树 (Gradient Boosted Decision Tree) 实现的优秀的机器学习框架之一，专注于类别特征的处理，解决了以往梯度提升树方法中的一些问题，在此基础之上进一步发展了最优化算法来处理类别特征^[19]。和 XGBoost 一样，使用 CatBoost 时也采用了集成学习的方法不断加入树来降低模型的预测误差，不同的是它可以在不需要经过独热编码等预处理步骤的情况下使用原始类别数据作为输入，所以可以直接将它们带入模型中进行学习。

CatBoost 改进了类别特征的处理，在传统方法中无法做到既不造成过多的计算成本又不影响信息量损失的同时，完成将类别型变量转化为数值型特征的过程。再辅以前进的目标编码方式，使得 CatBoost 更容易把握住类别特征与目标变量间的关系^[20]，并且可以自动处理缺失值（见图 1.1）；通过特征分裂优化、多线程并行以及“有序 Boosting”，能够大幅度提高训练速度，使用“有序 Boosting”来防止过拟合，以增加

模型的泛化能力。CatBoost 具有内建超参数调优的能力，对于金融风险建模、推荐系统、广告点击率预测等任务都比较适用，特别是针对规模较大的类别特征的数据集^[21]。




图 1.1 CatBoost 算法特征组合

(3) TabNet

TabNet 是一种结合了深度学习模型与决策树的优点,应用于表格数据上的模型。由 Google Cloud AI 提出，是在传统机器学习方法与深度学习方法中间进行架接的一种新的方式，如图 1.2 所示，它的主要优点就是可以通过自适应的选择重要的特征来模拟人类进行数据处理的过程，并利用一些具有解释性的框架来做决策^[22]。

TabNet 使用注意力机制进行自适应特征选择，选择当下最有效的特征，所以能够获得较好的性能及更强的可解释性；稀疏激活的方式减少计算量的同时提高了训练的速度和推理的速度，适合大样本数据集^[23]；TabNet 端到端地学习特征选择和决策规则，不存在于传统模型中较为繁杂过程，在解释性方面表现较好，应用到金融、医疗、用户行为预测等场景上有着天然的优势，对于一些高维度或海量数据而言都适用。




图 1.2 TabNet 决策步骤中特征选择和特征加权模块

1.3.2 智能优化算法

（1）遗传算法（GA）

遗传算法（Genetic Algorithm, GA）是利用模拟自然选择与自然遗传机制的原理设计出的解决最优化问题的一种随机化搜索方法。它是基于进化的思想，从一组随机生成的初始解出发，不断地应用自然选择、交叉和变异操作，在解空间中寻找全局最优解^[24]。利用 GA 对解空间的搜索特性，可应用于求解各种优化问题，包括求解非线性复杂的问题以及求解大规模问题等^[25]。

由于遗传算法具有在广大的解空间上搜索并避开了局部最优解的问题，所以选择种群初始化、评估个体适应度和选择父代、由交叉操作产生后代、运用变异操作增加种群多样性以及最后由适应度评估与替换的操作产生新种群的思路，以上即是 GA 的基本思想。GA 的优点是全局搜索能力强、灵活，容易适应各种问题，缺点是收敛速度慢、依赖于经验设置参数、只能解决问题的一个局部最优点等。GA 被广泛应用到函数优化、机器学习、路径规划、遗传编程等各个领域当中，且 GA 是在解决传统优化方法难以解决的一些复杂的问题时更为合理，应用性更强^[26]。

（2）粒子群优化（PSO）

一种模拟自然界鸟群觅食方式的全局优化方法——粒子群优化（PSO），该算法最早是在 1995 年由 Kennedy 和 Eberhart 所提出^[27]。通过模仿一群鸟儿的活动以及他们之间互相交流的方式来寻找群体的最优解。基本思想是在解空间中通过群体中每个粒子不停地搜索来尝试找到最优的位置，然后根据每个粒子过去的经验及整个群体过去的经历不断修正自身的位置来进行全局优化^[28]。

PSO 的基本原理主要包括初始化粒子群体、更新粒子的位置和速度、适应度评估及利用个体最优解（pbest）和全局最优解（gbest）来进行引导搜索。

速度更新公式：

$$v_i(t+1) = w \cdot v_i(t) + c^1 \cdot rand^1 \cdot (pbest_i - x_i(t)) + c^2 \cdot rand^2 \cdot (gbest - x_i(t)) \quad (1.1)$$

位置更新公式：

$$x_i(t+1) = x_i(t) + v_i(t+1) \quad (1.2)$$

粒子群优化优点在于全球搜索能力强，计算简便，容易实现，适应性强，能求解各种优化问题；缺点在于容易出现过早收敛，对参数比较敏感，难以保持群体的多样性。PSO 被用于函数优化、机器学习中的超参数调节、特征选择、图像处理、路径规划等领域，是一种有效的优化工具^[29]。

（3）贝叶斯优化（BO）

贝叶斯优化（Bayesian Optimization, BO）是一种全局优化方法，专门用于优化那些计算代价昂贵、黑盒且无法获取解析表达式或梯度信息的目标函数。它通过构建目标函数的代理模型，并利用这个模型来决定下一个查询点，以最小化目标函数的评估次数^[30]。

贝叶斯优化通过代理模型（通常为高斯过程）估计目标函数，并利用采集函数（如预期改进、概率改进、置信上限等）选择最优采样点。其核心思想是利用贝叶斯推断不断更新模型，平衡探索与利用^[31]。贝叶斯优化能够在计算代价昂贵的情况下，最小化评估次数并找到全局最优解，广泛应用于超参数调优、实验设计和自动化建模等领域。其优势在于全局搜索能力强、适应性广泛，并且能够避免传统方法陷入局部最优，特别适用于处理复杂的黑盒优化问题。

贝叶斯优化是对目标函数直接进行全局优化的一种方式，可以优化计算成本高昂且黑盒的目标函数，而无需解析表达式或梯度信息，同时用目标函数的代理模型代替目标函数并根据代理模型选择每次询问下一个最需要的知识的地方来达到最少次数的目标函数求值的目的^[32]。

贝叶斯优化使用代理模型（一般是高斯过程）预测目标函数值，利用采集函数（比如期望改善、概率改善、置信上限等）得到最优采样点，不断迭代的过程就是使用贝叶斯推断不断修正模型，然后去平衡探索与利用的思想，在很多的场景下能以较少的样本次数到达最小化的计算代价，从而获得全局最优解，最典型的有超参数调优、实验设计、自动化建模等场景^[33]。优点是在于全局搜索能力强，适用范围广，不需要陷入局部最优，能够避开传统方法的缺点，更能解决某些较为复杂的黑盒优化问题。

1.3.3 数字孪生技术

数字孪生技术（Digital Twin, DT）是多学科、多技术交叉融合的综合技术，要将数字孪生技术应用于冷轧连退带钢生产过程中，就需要集合物理模型技术、传感器技术、数据分析技术以及机器学习算法等多项技术要素^[34]。

在实现数字孪生的过程中，Unity 作为综合能力全面的 3D 引擎，通过与传感器、物联网等设备配合，可以实现对接冷轧连退带钢生产线上的实时温度、速度、压力等数据信息，并传送到 Unity 中，在虚拟环境中对其进行还原，并且对接接收到的数据库或是后端的信息进行相应参数修改，做到能够实时看到生产数据的变化，并且由于可以实时接入生产数据，为数字孪生提供精准的数据支撑。

结合力学性能预测模型（XGBoost、CatBoost）和数字孪生技术，在 Unity 中可将预测的结果以及工艺参数可视化，并且采用 3D 图形呈现抗拉强度(TS)、伸长率(EL)等力学性能指标，从而方便直观地了解到当前生产工艺的效果；通过物理建模和仿真，在 Unity 中模拟出不同的工艺参数对带钢性能造成影响的效果，给用户提供了一个动态的优化建议，通过虚拟环境的模拟，让用户能够快速准确地判断出工艺更改后的结果^[35]。

数字孪生最根本的价值即为实时回馈及闭环控制，Unity 在此起着关键的作用，操作人员通过交互式的界面就可以随时对虚拟系统中的工艺参数(如温度、冷却速度)进行修改，在线调整的过程中，系统会根据实际情况相应地改变带钢的状态、预测力学性能的变化；再通过与智能优化算法相结合，可以使 Unity 实现对生产过程的最佳决策建议，使得生产过程能够得到最精细的控制以及智能化的优化，这样可以使实际生产过程中始终保持最优的状态运行，从而提高了生产效率，保证了带钢产品质量的稳定性和一致性。

1.4 论文内容及组织结构

本文以冷轧连退带钢的力学性能预测作为研究对象，建立一种结合机理建模、机器学习的数据-物理混合建模方法，在利用智能优化及数字孪生技术的基础上，能够提高冷轧钢带力学性能预测精度并推广应用于工业生产中。同时本文重点说明了冷轧带钢力学性能预测技术和数字孪生在钢铁生产中应用的相关技术、经验和问题，为现有研究的内容补充了部分空白。本次研究实验设计流程如图 1.3 所示。

本节综述了相关研究的基础理论知识，在学习了相关背景理论后，介绍了影响冷轧带钢力学性能的因素分析、物理机理模型及数据驱动模型等；并基于多种先进结构化数据建模算法（XGBoost、CatBoost、TabNet）与智能优化算法（遗传算法、粒子群优化、贝叶斯优化），实现了模型的建立；通过对各模型的优劣对比，提升了预测精度和计算效率。

本研究以冷轧带钢为对象进行了机理建模研究，在此基础上结合模型物理机理与已有实验数据信息开发出了基于物理机理与数据驱动相结合的混合型机理模型。经过数据预处理、特征工程以及模型优化手段构建出若干种力学性能预测模型，并利用多种模型优点形成集成模型提高预测精度，且结合运用贝叶斯优化等智能优化方法对模型进行提升并完成可视化评价。




图 1.3 预测系统流程图

最后，本研究实现了基于数字孪生技术的力学性能预测系统，并把数字孪生技术和机器学习算法有机融合，在实现力学性能数据的实时反馈的同时也给工业生产提供了在线监测以及质量优化方面的支持。

2 冷轧带钢连退生产工艺机理解析

2.1 引言

冷轧带钢作为重要的工业基础材料，在汽车、建筑及家电等行业中有很大的应用范围，冷轧带钢力学性能（包括抗拉强度 TS、延伸率 EL、屈服强度 YS）决定冷轧带钢的可加工性及服役寿命，也是冷轧带钢主要的质量指标之一^[36]。针对带钢力学性能的预测问题，相关研究者分别从理论分析方面出发，构建多种建模方案，并且逐步由单一的基于经验的传统建模方法向结合物理机理及数据分析的方法转变^[37]。针对目前力学性能预测中准确度较低的问题，在此通过将传统方法和机器学习算法结合的方式，提出了对力学性能进行精准预测的方法。

本章详细介绍了冷轧带钢力学性能预测的理论基础和技术手段，对目前常用的预测建模方法进行了分析对比，并就基于数据—物理融合新的预测模型进行了重点阐述。

2.2 冷轧连退带钢的力学性能影响因素

冷轧连退带钢的力学性能是由多个因素共同决定的，主要包括材料的化学成分、晶粒尺寸、冷轧与退火工艺条件、应变速率效应等^[38]。以下将逐一讨论这些影响因素，并结合相关文献进行阐述。

2.2.1 化学成分

钢铁材料的化学成分特别是碳、锰、硅等元素的含量直接影响到冷轧带钢的力学性能；碳是提高强度的元素，但也会降低其塑性；锰提高钢的强度、硬度及抗氧化性，并改善低温韧性；硅有利于提高钢的抗氧化性，在高温下有很好的抗氧化保护作用。

通过调整钢的化学成分，控制好碳、锰及硅的比例，可以使得钢材的强度及延展性的参数都处在一种良好的水平上，更具有整体性的综合优势^[39]。例如：适当提高锰含量可以使冷轧带钢的抗拉强度增加大约 10%，但是如果锰含量过多会降低其塑性。

2.2.2 晶粒尺寸

晶粒大小对冷轧带钢的力学性能有很大影响，在霍尔—佩奇（Hall-Petch）关系^[40]中，指出晶粒细化可以使材料强度得到大幅提高，冷轧时，随变形量的增大晶粒尺寸不断减小，在此过程中可明显观察到晶粒细化、减小的效果，其依据在于小晶粒能够大幅度提高材料强度，由于晶界强化作用，所以能有效阻止外力引起的滑移运动。

根据实验表明,将晶粒由 10 微米降低到 2 微米时,带钢的屈服强度提升约 30%,但进一步的晶粒细化会使得材料出现更为严重脆性,因此,在提高强度的同时还要兼顾材料的韧性, 需要达到两者之间的平衡状态^[41]。

2.2.3 冷轧与退火工艺条件

冷轧和退火都直接影响带钢的力学性能,冷轧过程会使得带钢产生应变强化,带钢的强度随变形量的增大而增大^[42];退火是将带钢加热至某一温度并保温一段时间以消除带钢冷轧时所引起的内应力,然后冷却恢复塑性,并且可以控制晶粒长大,稳定带钢性能。

不同类型的冷轧和退火操作将形成不同的晶粒度和相变,从而影响力学性能。从 Yang 等人^[43]的研究结果中得知,当选用合适的退火温度(600~700℃)时,经过冷轧后轧制方向上组织会变成亚稳态。高温退火有利于应力的减小及塑性的恢复,但若退火时间过长,则会出现晶粒粗化现象,导致钢材的强度下降。

2.2.4 应变速率效应

定义为在一般情况下,在应力—应变曲线上最大变形增量相对于总变形增量的数值百分比或大小量。冷轧带钢的力学性能受应变速率影响较大,在较高的应变速率下,带钢的屈服强度、抗拉强度均有所提高,而塑性下降^[44],其原因主要是由于应变速率硬化的缘故,即当应变速率增大时,由于位错运动被阻隔,位错密度增大,故使材料的强度得以提高。

研究表明应变速率对冷轧带钢的力学性能有重要影响。高速拉伸时带钢的强度能提高 20%以上,但延展性略有下降^[45]。因此,在冷轧带钢的轧制过程中要合理地控制应变速率,有利于改善带钢的力学性能。

2.2.5 其他因素

除了前面提到的重要因素外,还有其它因素例如冷轧带钢的加工硬化、退火过程中发生相变和生成氧化膜等也会影响冷轧带钢力学性能;带钢的应力—应变行为、破断机理等方面的探讨还有许多,如加工硬化模型、超塑性行为^[46]。另外,由于材料表层状态以及微观缺陷的存在(如孔隙、裂纹等),会使冷轧带钢的力学性能出现严重下降。此外,表层状态如粗糙度、脱碳层或残余应力的分布,也可能在一定程度上诱发宏观破断或疲劳失效。冷轧带钢的力学性能并非单一由工艺参数所决定,而是多种尺度效应与多物理场交互作用共同影响的产物。从微观组织演化到宏观工艺过程,各因素之间存在复杂耦合关系。

2.3 冷轧过程中间变量

2.3.1 晶粒尺寸（CD）模型

晶粒尺寸（CD）是影响金属材料力学性能的重要参数之一，在冷轧带钢力学性能测试中，晶粒尺寸也决定了钢带强度和塑性、硬度等各种性能；根据经典 Hall-Petch 关系可知，晶粒尺寸与材料的屈服强度（YS）、抗拉强度（TS）有着十分密切的关系^[47]，晶粒越细，则钢材强度越高；若晶粒过大则会降低材料的力学性能。为能准确地预测出冷轧带钢的力学性能，需建立晶粒尺寸（CD）模型，定量表示晶粒尺寸与钢材强度的关系。

Hall-Petch 关系与晶粒尺寸模型：

根据 Hall-Petch 理论，晶粒尺寸对屈服强度的影响可以通过以下公式描述：

$$\sigma_y = \sigma_0 + k \cdot d^{-\frac{1}{2}} \quad (2.1)$$

其中， σ_y 是屈服强度， σ_0 是材料的固有强度， k 是 Hall-Petch 常数， d 是晶粒尺寸。从上式中可以看出，当晶粒尺寸 d 减小时，屈服强度 σ_y 会增加，且其增幅呈现出根号倒数的关系。这个关系体现了晶粒尺寸对材料强度的增强作用，晶粒尺寸减小则能提高材料的强度，因而晶粒越细，材料强度越高。

晶粒尺寸对冷轧带钢的力学性能有重要影响，Hall-Petch 关系说明了晶粒越小，抗拉强度和屈服强度越大，但过细的晶粒可能会使材料变得脆弱，因此要兼顾强韧性的平衡。因此，控制冷轧带钢晶粒尺寸的方法为：冷轧带钢在热轧以及冷却过程中调节热轧温度、冷却速度和合金成分等，进而控制带钢晶粒尺寸大小^[48]。

2.3.2 碳当量（Ceq、Pcm）模型

碳当量是衡量钢材中不同合金元素对钢材性能（尤其是焊接性和热处理反应）的影响的重要参数^[49]。它通常用于评估钢材在焊接过程中可能出现的裂纹风险以及钢材的强度和韧性之间的权衡。

碳当量的计算公式为：

$$C_{eq} = C + Mn / 6 + (Cu + Ni) / 15 + (Cr + Mo + V) / 5 \quad (2.2)$$

$$P_{cm} = C + Si / 30 + Mn / 20 + Cu / 20 + Cr / 20 + Mo / 15 + V / 10 + 5B \quad (2.3)$$

在其中， C 表示碳含量， Mn 表示锰含量， Cr 、 Si 、 Mo 、 V 、 Cu 分别是其余合金元素的含量。

碳当量可以准确的反应出碳钢中合金元素总量的影响。钢材强度及硬度：碳当量

越高，说明钢材的强度与硬度越高，由于合金元素的加入能增加钢的晶格强化效果，从而提升了钢的抗拉强度以及屈服强度；碳当量越高，则表明在焊接时产生的热影响区域越大，在冷作校正时更容易发生裂纹，使得钢材的韧性以及焊接性能降低；碳当量能够体现钢材的焊接性以及热处理性能^[50]。

碳当量是表示钢材成分的物理量，在相变模型中经常用到；碳当量大小会对材料的相变产生影响，从而影响相变速度和最终得到的微观组织，合理地控制碳当量可以使获得性能更好的钢材。

2.3.3 活化能（Q）模型

活化能（Q）是表征金属材料在高温下塑性变形能力的一个重要参数，它是用来表征金属在不同的温度下发生变形行为的一个指标，同时它还和材料的流动应力、变形速度等相关，因此活化能的概念是在 Arrhenius 描述化学反应速率中提出并被广泛应用到金属塑性变形中，在冷轧带钢力学性能预测中，通过对温度对应力-应变行为的影响建模得到活化能，以此可以对材料的性能进行预测^[51]。

计算公式为：

$$Q(J \cdot mol^{-1}) = 124714 + 28385.68 \cdot Mn + 64716.68Si + 72775.4Mo + 7683.32Ti^{0.213} + 121100.37Nb^{0.1} \quad (2.4)$$

2.4 本章小结

第二章对冷轧连退带钢力学性能的预测进行了总结，结合材料学知识，分析了冷轧带钢力学性能的影响因素，具体包括化学成分、晶粒尺寸、冷轧和退火工艺条件以及应变速率等因素，并指出了这些因素对力学性能指标（TS、EL、YS）有着不同程度上的相互促进或者抑制作用。

此外，晶粒尺寸（CD）、碳当量（Ceq、Pcm）和活化能（Q）作为冷轧过程中具有物理意义的重要中间变量，建立了微观组织与宏观力学性能之间的桥梁。通过引入 Hall-Petch 关系、碳当量模型和活化能模型，增强了模型的物理解释性，也有效提升了性能预测的准确度。这些变量作为数据与机理融合建模中的关键特征，为后续模型构建提供了理论基础和参数支撑，进一步推动了冷轧带钢力学性能预测的精度与工程适用性的提升。

3 基于机理模型的冷轧带钢质量力学性能预测

3.1 建模思路与整体框架

冷轧带钢机理建模是冷轧钢材生产的核心环节之一，通过对建模方法的优选，在考虑物理模型与数据驱动模型的基础上进行求解，可以得到带钢的力学性能并利用建模得到的结果，优化生产工艺。冷轧带钢的力学性能抗拉强度（TS），伸长率（EL）及屈服强度（YS）受众多因素的影响，例如原料成分、工艺参数以及在轧制过程中的温度和冷却速度等，而为了模拟以上影响因素，建模思路可以分为物理机理建模以及数据驱动建模两种方式。

物理机理建模是依据材料的微观结构，结合生产工艺推导相关物理模型的过程，晶粒尺寸（CD）、碳当量（Ceq）和活化能（Q）等因素均属于此类物理量，它们影响着带钢的力学性能：晶粒细化可使材料的强度得到大幅提高；适当的碳当量可保证材料成分满足要求并受控，在不同条件下得到的组织和性能也符合要求。通过冷轧过程中发生变形、相变以及温度分布规律建立数学模型作为数据驱动模型的物理参数，得到更为精准的数据驱动模型预测结果。

基于数据驱动建模的方法利用了机器学习（XGBoost, CatBoost 等）技术，通过对大量的历史生产数据进行学习，发现了不同工艺参数与力学性能之间的联系。数据驱动模型可以根据输入的数据直接输出结果，能够解决大规模问题，并且具备描述冷轧过程中非线性关系的能力。

通过将物理机理模型和数据驱动模型进行融合建模，在少量实验数据的基础上也能够得到比较准确的结果，并且给出实时的性能优化方案；基于这一类融合建模方法具有更高的预测准确度，在线实现了生产工艺参数的调节以及生产过程的优化，并最终改善带钢产品质量与稳定性。

从整体框架上看，冷轧带钢机理建模包含材料成分、工艺参数等输入信息，基于此建立有物理特性的模型（如 Ceq、Q、CD 等）；再结合数值仿真及实验数据，建立力学性能预测模型。

同时使用智能优化算法（如贝叶斯优化算法），通过对模型进行调优的方式，进而实现在此基础上得到的更加精确的工艺控制及性能预测。利用上述多层次、多方面的建模框架体系，进一步提高冷轧带钢整个生产过程的效率及质量。

3.2 数据来源

本文所使用的数据取自某钢铁企业 2024 年 1—4 月冷轧连退的整个生产过程中的产品跟踪数据，数据格式为 csv 文件，主要是冷轧带钢在生产过程中各工序的工艺设定、化学成分配方、热处理温度、设备参数和力学性能等数据，原始数据共计 11348 组样本数据，包含冶金工艺参数（加热温度、卷曲温度）、机械负载（轧制力、弯辊力）、带钢物理参数（厚度、宽度）、各段温区（JPF、SF 等）、常见化学元素（C、Mn、Si、P、S、Cr 等）组成变量，目标变量为屈服强度（YS）、抗拉强度（TS）、伸长率（EL）。

3.3 特征选取与字段清洗

原始数据中含有部分与预测目标关联度低或缺少较多的特征，在进行数据预处理时首先统一了列名格式，并删除了无效空值以及零值记录以保证后续模型训练使用的数据能足够可靠；又对关键性能指标（屈服强度、抗拉强度、伸长率）为 0 和缺失的部分进行剔除操作，得到大约 6000 组有效数据，用于后期建模。

3.4 关键机理特征构造

结合钢铁冶金相关的理论，针对带钢性能的影响因素可以构造多个机理特征，用来提升模型的物理合理性和预测能力。本研究选择机理特征碳当量（ C_{eq} ）、活化能（ Q ）、晶粒尺寸（ CD ）作为中间变量，具体公式推导在上一章节有所提及。

3.5 建模方法简介

该阶段利用基于机理特征的机器学习方法（如 LR（线性回归）、SVM（支持向量机）），对力学性能进行预测，并通过机理特征有效性和解释性的验证，最终选择模型效果最好的作为研究对象，在下一章会通过引入智能优化算法实现更优的综合优化。

3.6 模型训练与结果分析

3.6.1 数据集划分与模型训练

为了科学评价基于机理特征的力学性能预测模型，根据常用的划分比例（训练集 80%，测试集 20%）对处理后的数据集进行切分，训练集用于训练学习模型的参数，

测试集用于检验模型的泛化能力。

模型训练时，将含有化学成分、工艺参数、结构的机理特征作为输入变量，分别用线性回归、多项式回归和支持向量回归（SVR）等回归模型进行拟合，在调整超参数的过程中不断地进行学习，并由此达到对模型拟合度的最优化。为了避免过拟合与提高模型的稳定性，在训练过程中使用 5 折交叉验证（K=5）以使模型在每一个子样本上都能达到较好的效果。同时，在训练过程中对损失函数的变化情况进行持续性的观察，保证模型在训练期间能达成正确的收敛，从而可以保证最终得到的模型预测结果能够具有较高的精度和良好的鲁棒性。

3.6.2 模型对比分析

根据前面章节的相关分析，为了全面考察基于机理特征力学性能预测模型，从 3 种常见的机器学习回归算法中挑选 XGBoost、随机森林（Random Forest）和 SVM 这 3 种进行对比试验，且各模型均在相同的训练集和测试集上训练并验证。各模型经训练得到后利用其在测试集上的预测值与真实值进行比较，均分别使用均方根误差（RMSE）、平均绝对误差（MAE）以及决定系数（R²）来评判模型的优劣，结果如表 3.1 所示。

表 3.1 各模型在测试集上的性能对比

模型	性能指标	抗拉强度 TS	伸长率 EL	屈服强度 YS
XGBoost	RMSE	4.55	1.21	7.29
	MAE	2.89	0.83	4.06
	R ²	0.9554	0.8283	0.9631
Random Forest	RMSE	4.48	1.11	7.15
	MAE	2.76	0.75	3.78
	R ²	0.9569	0.8555	0.9646
SVM	RMSE	14.60	1.68	20.22
	MAE	6.66	1.29	9.55
	R ²	0.5412	0.6707	0.7166

XGBoost 模型预测结果精度较高，RMSE 与 MAE 均较小，R²均接近于 0.96，证明该模型拟合程度较好，预测误差较小；随机森林（RF）模型整体上性能较为接近，XGBoost 模型，但在伸长率（EL）预测方面稍好，R²达到 0.8555，说明该模型对于该目标变量的拟合效果更佳；支持向量机(SVM)模型各个性能指标均较差，尤其以 TS、YS 的 RMSE 远大于二者，且 R²偏低，说明该模型拟合性差、预测稳定性差。

综上所述，XGBoost 和随机森林都具有良好的机理特征力学性能预测能力，两者性能相差不大，均有较强的非线性拟合能力及抗过拟合能力，XGBoost、随机森林在预测硬度时优于其它模型；而随机森林预测伸长率的效果略好于 XGBoost 可能是因为基于多棵决策树组合形成随机森林的方式更利于提取伸长率这一指标的变异性；另外，XGBoost 采用梯度提升方法来优化每个新模型所产生的误差，进而优化整体模型的性能。

根据以上分析可知，本次实验选取 XGBoost 作为后续实验主要采用的模型，并基于机理特征进一步实现模型参数优化、模型性能优化与模型可视化分析等工作。

3.7 机理模型性能预测

为了提高模型性能及增强模型的物理可解性，在此引入了包含一定工艺物理意义的中间变量（碳当量、活化能等）来代替桥梁变量，从而用增加桥梁变量数量的方式来丰富模型，即将模型结构从“原始工艺特征力学性能”扩展至“原始工艺特征中间变量力学性能”。

表 3.2 展示了引入中间变量前后模型在测试集上的性能指标对比：

表 3.2 引入中间变量前后模型指标变化

模型结构	R ²	RMSE (MPa)	MAE (MPa)
原始特征直连模型	0.821	12.37	8.12
引入中间变量的嵌套模型	0.912	9.61	6.35

中间变量对带钢力学性能预测的影响对比加入和未加入中间变量情况下各种模型预测情况，图 3.1 分别表示了线性回归（LR）、随机森林（RF）、极端梯度提升（XGBoost）、神经网络（NN）两类情况下 R^2 分数的变化情况。由表 3.2 可知，在加入中间变量时，各模型的 R^2 值均有不同程度的提高。LR 模型提高了 0.038，RF 模型提高了 0.017，XGBoost 模型提高了 0.015，NN 模型提高了 0.017，集成模型提高了 0.014，可见中间变量对于模型拟合能力具有较大的改进作用。最后可以看出中间变量的加入对各单一模型预测准确率均有所提高，并且也大大提高了集成模型的综合性能，证明中间变量在带钢力学性能建立模型中的有效性与重要性。




图 3.1 不同模型引入中间变量指标 R^2 对比

3.8 本章小结

本章主要阐述了冷轧带钢力学性能预测中机理建模的关键方法,包括碳当量(C_{eq})计算、活化能(Q)模型构建和晶粒尺寸(CD)模型推导。首先基于碳当量计算确定合金元素对冷轧带钢力学性能的影响,讨论碳当量与材料热加工性能的关系;其次,根据活化能模型基于温度、应变速率变化说明材料的不同工艺下流变应力特性的差异性,从而为冷轧过程的温度控制提供参考;最后根据晶粒尺寸模型表征不同热处理条件下晶粒的变化情况,分析晶粒细化对冷轧带钢力学性能的改善作用。

本章通过材料成分、热处理行为及微观组织等建立了表征冷轧带钢力学性能的关键物理模型,在此基础上建立了基于碳当量、活化能与晶粒尺寸的模型,并揭示了工艺参数对于微观组织演变及力学性能的影响规律;此外,为后续开展基于数据驱动的模型进行了可靠的物理特征准备。基于前述机理模型,在下节数据—物理融合预测部分作数据—物理融合建模的核心输入变量。

4 基于机理与进化学习的冷轧带钢质量力学性能预测

4.1 数据预处理与特征工程

4.1.1 数据清洗与缺失值处理

数据清洗的主要作用是保证数据集的质量与有效,能够更好地使得模型的预测精度与稳定度得到提升。将数据导入,采用 `pandas` 方法先读取原始冷轧钢带生产数据文件(CSV 格式),再使用 `df.head()`、`df.shape` 等方法查看数据表的总体结构;数据采集都属于非标准状态下的,所以或多或少会存在列名出现前空格或者后空格、编码错误等情况,再加上可能存在有未读出或者乱码的情况,为了避免列名读取之后产生错误与理解上的偏差,在确定初始数据基本情况之后进行列名统一性处理,使用 `str.strip()` 去除字段中的空白字符,然后对列名进行人工校正调整。

基于冷轧连退带钢力学性能预测的目标,建立一个包括成分(C、Mn、Si.....)、工艺参数(炉温、冷却速度、卷厚等)、目标性能指标(屈服强度、抗拉强度、伸长率.....)的特征变量集。用遍历方式检验数据集中各字段是否完整,如缺少字段数据,则终止后续操作,并给出错误提示信息,保证后期分析合理有效。

结合工业数据中较为常见的缺失情况,利用基于特征列的有条件剔除法处理。只删掉目标列(比如力学性能指标和核心工艺变量)存在缺失的这一行,若某一行的上述字段中有缺失,则整个该行都会被删掉。这能够保证一定的样本量,而且不会有大的偏差,在保证一定精度的同时也能保留充分的数据量,不至于过多地删除造成样本量变小。

此外,为保证模型训练物理意义的一致性,继续剔除目标列数据中出现为零值的数据。这类零值,在实际工业生产中是没有物理意义的,可能是由传感器故障,数据丢失,或者数据录入错误造成的,对于模型训练有非常大的干扰作用。其次,特征维度大小不一致,在建模时会引起模型对大的特征数值重视度更大,对小的特征数值重视程度更小,进而使得学习到的结果不尽如人意。因此,本文选用 `MinMaxScaler` 将原始特征的取值归一化到[0,1] 范围内。

完成数据清洗之后把清洗过的数据集保存到指定的目录里面,在日志中记录下处理时间和字段的状态,方便以后的模型调用和实验的重现;且需要保留映射关系以及清洗规则,在以后的数据更新或者是模型迭代时能够实现前后保持一致性的回溯。

本文对工业生产数据中原有的缺失值、异常值以及多余的字段进行了清理，利用字段标准化的方法去掉重复字段，用删除异常值的方式消除缺失值，用去除零值进行值域预处理和数据归一化处理等手段提高了数据质量和特征表示的一致性，为进一步建立高精度、多目标冷轧带钢力学性能预测模型提供可靠的数据信息基础。

4.1.2 特征归一化与选择

为了让机器学习模型用于冷轧带钢性能预测任务时能够更好地完成训练和达到最佳的泛化效果，在对原始数据进行了清理以后，对其中的特征变量进行了归一化和特征选择处理。其目的在于去除一些冗余或者无关的特征，只保留下对应目标变量重要的关键特征，来提升模型的可读性和稳定性。

而在工业制造数据中的不同特征存在不同的物理量纲以及数量级大小，在诸如化学元素的质量分数可能处于 0.001-1，而工艺参数（温度、速度）的值却可能达到上百甚至上千数量级。这样当其作为输入量加入机器学习模型后，会出现有的大数量级会对损失函数起到决定性作用，影响了模型的收敛速度和效果问题。

为了达到这个目的，本次研究用最小-最大归一化（Min-Max Normalization）方法将所有的数值型输入变量都进行缩放处理，如式 4.1 所示。

$$X_{norm} = (x - x_{min}) / (x_{max} - x_{min}) \quad (4.1)$$

将 x 归一化到[0,1]区间，则有。这是因为经过归一化之后的数据落在了这个区间内，既可以保证模型训练时的数值稳定性又可以避免梯度下降中出现某一部分的值偏大的情况，对于后续的数据优化更加有利。

通过 `sklearn.preprocessing.MinMaxScaler` 做归一化，并且将归一化的参数保存下来，在用于测试数据时能保证训练和预测时所用到的参数一致，具体如下。

化学成分、工艺参数和控制变量都出现在原数据集当中，有些特征之间可能存在较强的共线性或者对因变量的影响并不大，因此在本文提出了将先使用变量相关性的两阶段特征选择方法。

（1）基于物理知识的初筛

首先，根据冷轧带钢成分及工艺对其力学性能产生影响的机理，结合冶金知识从变量当中初筛相关因素。并保留与相变行为和强度有关的化学元素（即 C、Mn、Si、Nb、Ti 等）以及与关键工艺参数（即加热温度、冷却速度、炉速、卷取温度等）有关的因素，去除一些无用的字段（如序号、时间戳、多余批次号）以及不能获取的变量。

（2）基于数据驱动的自动选择

在初筛基础上,进一步引入数据驱动的特征重要性评估方法,辅助筛选关键变量。具体方法包括:

基于相关系数的过滤(Filter Method):计算各输入特征与目标变量(如屈服强度、抗拉强度、伸长率)之间的皮尔逊相关系数,剔除绝对值小于设定阈值(如 0.05)的变量;

$$r_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) / (\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}) \quad (4.2)$$

根据前面模型嵌入的方法中用到的是通过基于树的模型(如 XGBoost 和 Random Forest),它将样本来训练并得到每个特征的重要性分数(feature importance),按照得分高低顺序来排在前面 n 位的作为待选的变量输入后续模型使用。评分靠前的 n 个变量保留,在后续模型中作为输入变量使用。

逐步回归与共线性检测:利用结合逐步特征加入(Forward Selection)和方差膨胀因子(VIF)剔除存在较高共线性的特征以去除模型的冗余变量,避免对建模过程产生影响。

在用这种方法得出结论之后,建立起了一个包含了九个化学成分变量和十个工艺参数变量作为输入特征集的数据,涉及到的有:热处理路径、组织转变控制、强度调控方式等等,各个特征均已归一化,并且对目标变量有着较高的相关性。

4.2 模型结构与输入特征设计

为了解决冷轧连退带钢关键力学性能(屈服强度 YS、抗拉强度 TS、延伸率 EL)精度预测问题,建立基于机器学习的回归建模框架,根据工业数据的特点及物理机制的影响因素,设计模型结构和输入特征结构,主要包含多目标预测策略选择、输入特征编码方式、模型输出结构等方面的内容。

4.2.1 输入特征设计

结合前述特征选择结果,本文构建了包含化学成分与工艺参数的输入特征集,用以充分表征原材料属性与热处理路径的综合影响。最终模型输入特征向量定义如下:

$$X = [C, Mn, Si, P, S, Al, Nb, Ti, Cr, TA, TB, TC, V1, V2, Cc, RT, UT, CT] \quad (4.3)$$

其中化学成分特征 9 项,包括碳(C)、锰(Mn)、硅(Si)、磷(P)、硫(S)、铝(Al)、铌(Nb)、钛(Ti)、铬(Cr)等主要合金元素质量分数;

热处理路径特征(10 项):包含不同的阶段退火温度(TA, TB, TC),炉速(V1, V2),

冷却速率(Cr)，冷却时间(Cc)，卷取温度(RT)，卷取速度(UT)以及冷却温度(CT)。

采用最大最小归一化方式把所有特征都转化为[0, 1]之间的值，为模型训练时输入的一致性及梯度稳定性做保障。

4.2.2 多输出进化学习模型

由于目标变量涉及三维的相互关联，而且物理机理不同，同时表达强度和塑性两大类力学指标，因此单目标建模方法在优化过程中往往容易出现三个目标变量不能同时最优的结果，导致预测性能失衡。本文采用了“多输出回归(Multi-output Regression)”的方式将三个目标变量合成联合输出向量。

$$Y = [YS \quad TS \quad EL] \quad (4.4)$$

该策略不仅可显式建模各目标之间的相关性，有助于捕捉多性能之间的协同变化规律，还可减少训练代价与冗余计算，提升整体建模效率。

4.2.3 进化学习优化方法

本次研究为了提升冷轧带钢力学性能预测模型的精度，在建模过程中需要对模型的关键超参数（如树的最大深度、学习率、子样本比例等）进行优化。传统的网格搜索(Grid Search)或随机搜索(Random Search)在高维超参数空间中搜索效率低、成本高。由此本研究引入贝叶斯优化(BO)作为进化学习策略，基于概率模型的方法对目标函数进行迭代优化。通过采集函数(Acquisition Function)引导下一个最有可能取得最优结果的超参数组合，从而在最少评估次数下找到最优解。其核心思想是构建一个代理模型（通常为高斯过程）对真实目标函数进行逼近，然后在此代理模型上选择下一个评估点，从而逐步逼近最优解。目标函数的定义如下：

$$L(\theta) = (1/n) \cdot \sum_{i=1}^n (\alpha_1 \cdot RMSE_{YS}^{(i)} + \alpha_2 \cdot RMSE_{TS}^{(i)} + \alpha_3 \cdot RMSE_{EL}^{(i)}) \quad (4.5)$$

其中 θ 为模型待优化的超参数集合； $RMSE_{YS}^{(i)}$ 、 $RMSE_{TS}^{(i)}$ 、 $RMSE_{EL}^{(i)}$ 分别为模型在第*i*次交叉验证中对屈服强度(YS)、抗拉强度(TS)、延伸率(EL)的均方根误差； α_1 、 α_2 、 α_3 为对应指标的权重因子，需满足三者和为一；*n*为交叉验证折数，本次研究选择*n* = 5。

此目标函数以多目标误差加权求和形式提升模型整体性能，目标在于最小化预测误差，同时保证各项性能指标平衡。同时避免模型在某一性能指标上取得较好结果而牺牲其他指标的预测准确性。通过合理设定权重因子，可以在不同预测任务之间进行灵活的权衡，从而达到各项力学性能指标的平衡最优。通过有限次数的目标函数评估，BO 能够在复杂高维的超参数空间中快速收敛至近似最优解，有效提升模型的泛化能

力和稳定性。

4.3 模型训练与评估方法

4.3.1 参数设置

为了提高预测模型对冷轧连退带钢力学性能（包括 TS、EL、YS）预测的准确度，本文利用 XGBoost、CatBoost 和 TabNet 三种回归模型对其进行训练，并且采用贝叶斯优化或模型自带的验证方式调优相应模型的超参数，使得模型在兼顾泛化能力和收敛速度的情况下达到较好的效果，其中各模型的参数设置情况见表 4.1。

（1）XGBoost 参数设置

XGBoost 模型使用 `xgboost.XGBRegressor` 实现，采用 5 折交叉验证评估模型性能，并利用贝叶斯优化算法自动搜索最优超参数。核心参数设置如下：

表 4.1 XGBoost 核心参数设置

参数名称	说明	最优取值示例
<code>learning_rate</code>	学习率，控制每棵树的权重更新速率	0.07 ~ 0.15
<code>n_estimators</code>	弱学习器（树）的数量	200 ~ 500
<code>max_depth</code>	树的最大深度	4 ~ 8
<code>min_child_weight</code>	子节点最小样本权重和	1 ~ 5
<code>subsample</code>	每棵树使用的样本比例	0.6 ~ 0.9
<code>colsample_bytree</code>	每棵树使用的特征比例	0.6 ~ 1.0
<code>reg_alpha</code>	L1 正则化项系数	0 ~ 1
<code>reg_lambda</code>	L2 正则化项系数	0 ~ 5

（2）CatBoost 参数设置

CatBoost 模型采用 `catboost.CatBoostRegressor` 实现，在使用模型 `cv()`函数评估出的各参数组合中选出最优参数组合作为模型；使用多进程并行的方式完成对可能的参数组合的搜索。由于模型中用到的特征都属于类别特征，所以使用了 `cat_features` 的方式显示指定了所有的类别特征。

考虑到输入特征中包含大量的类别变量（如钢种等级、机组编号、工艺路线等），模型中通过 `cat_features` 参数显式指定所有类别特征，以确保 CatBoost 内部能够正确处理并自动执行最优的目标编码与分裂策略。为防止过拟合并提升模型鲁棒性，训练中还结合了早停机制（`early_stopping_rounds`），在连续若干轮迭代未取得性能提升

时提前终止训练,从而获得泛化能力更强的回归模型。相关的主要参数设置见表 4.2。

表 4.2 CatBoost 核心参数设置

参数名称	说明	最优取值示例
iterations	最大迭代次数	1000（含早停机制）
learning_rate	学习率	0.01 ~ 0.2
depth	树深度	4 ~ 10
l2_leaf_reg	L2 正则化系数	0.5 ~ 5
border_count	类别特征离散化边界数量	32 ~ 255
subsample	子样本比例	0.5 ~ 1.0
random_strength	控制模型随机性的强度	0.5 ~ 5
early_stopping_rounds	提前停止的轮数	50（固定）

（3）TabNet 参数设置

TabNet 模型为深度学习结构,适用于结构化数据。本文采用 pytorch-tabnet 库中的 TabNetRegressor 模型,对不同目标特性分别进行训练。主要参数设置如下:

表 4.3 TabNet 核心参数设置

参数名称	说明	设置值
n_d, n_a	决策/注意力单元维度	8
n_steps	决策步骤数	3
max_epochs	最大训练轮数	200
patience	早停容忍轮数	10
optimizer_fn	优化器	Adam
scheduler_params	学习率调度器参数	100
verbose	输出频率	默认关闭

4.3.2 多输出回归策略与评估指标

为了解决冷轧连退带钢的力学性能预测问题,基于多输出回归（Multi-outputRegression）框架融合预测抗拉强度（TS）、伸长率（EL）以及屈服强度（YS）三个目标值,当目标值之间存在一定的联系时,单独训练独立模型未必能有效利用各个目标值之间的关联信息。对此尝试了以下 2 种多输出建模策略。

建立独立建模（Independent Models）,即用 3 个单独的单输出回归模型分别进行建模,之后作为基准方案。

使用联合建模（MultiOutputRegressor）将原有的回归器（如 XGBoost）以 MultiOutputRegressor 的方式应用到其余的维度上，在本次实验中，分别使用同一种回归器实现不同输出的目标函数拟合。

此外，在集成模型中嵌入了物理机理特征（如碳当量、晶粒尺寸），增强了模型泛化能力；通过贝叶斯优化算法调优超参数，提高了多输出回归预测精度。

4.3.3 模型评估指标

为系统评估多输出回归模型的预测性能，本文采用以下三类常用的回归评估指标：

均方根误差（Root Mean Square Error, RMSE）

$$RMSE = \sqrt{(1/n) \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (4.6)$$

该指标对预测误差较大的样本更为敏感，可反映模型整体的稳定性和稳健性。

平均绝对误差（Mean Absolute Error, MAE）

$$MAE = (1/n) \cdot \sum_{i=1}^n |y_i - \hat{y}_i| \quad (4.7)$$

表示预测值与真实值之间的平均绝对差值，反映模型的平均误差水平。

判定系数（R-squared, R^2 ）

$$R^2 = 1 - \sum_{i=1}^n (y_i - \hat{y}_i)^2 / \sum_{i=1}^n (y_i - \bar{y})^2 \quad (4.8)$$

表示模型对数据方差的解释能力，其取值范围为 [0,1]，值越接近 1 表示模型拟合效果越好。

在模型训练与测试阶段，分别对 TS、EL、YS 三个目标变量计算上述指标，并对比各回归模型在不同建模策略下的性能表现，进而评估多输出回归方案的有效性

4.4 模型对比与分析

在本研究中，为精确预测冷轧连退带钢 TS、EL、YS 三种力学性能，建立各种机器学习回归模型，并利用融合建模方法以提高其性能，把比对模型用到了 XGBoost、CatBoost、TabNet 等常见的梯度增强类模型以及基于融合物理机理特性和贝叶斯优化法的多输出模型上；图和表显示了不同模型对这 3 个目标变量的预测效果及相应的评价指标。

由实验结果可知：相比于单个模型，XGBoost 模型综合性能最好，且在 TS、YS 方面均能达到较高水平；CatBoost 模型在 TS 方面能与 XGBoost 相媲美，但是 EL 和

YS 方差相对较大；TabNet 模型因为其训练机制原因对于样本规模比较敏感，该任务下模型性能不如 XGBoost 和 CatBoost，但后期还有一定的改善空间。

从上面的基础上，本文进一步提出了融合建模方案，在融合过程中引入基于物理机理推导出的关键特征变量（如碳当量、晶粒尺寸、扩散活化能等）提高模型对材料微观组织变化的感知程度；其次，在模型融合过程采用贝叶斯优化自动调节模型超参数的方法代替传统调参手段以克服传统调参方法弊端，达到提高建模效率和增强泛化能力的目的。

该模型在 TS 和 YS 两个指标下也得到了比其他的模型更高的预测精度和一致性，即：将机理特征加入到 BO-XGBoost 后得到的 TS 对应 RMSE 值由原来的 5.21 降低为 3.99，TS 对应 R^2 提高到了 0.966，这说明了这种通过混合建模的方式结合物理知识及先进优化方法以实现多模型的集成，在其参与机理特征、以及自适应调优这两点都占有一定优势，发挥了数据驱动的优势，成为提高复杂工艺产品性能预测精度的重要途径。

此外，融合模型在三个目标变量之间的误差更加均衡，因此较其它模型在多输出回归任务中有更好的稳定性以及较好的推广应用价值。由表 4.4 可以发现本文融合建模策略对于冷轧带钢力学性能预测有良好的工程应用意义和实践价值。

表 4.4 不同模型在各性能指标下的 RMSE 与 R^2 对比

模型	TS (RMSE / R^2)	EL (RMSE / R^2)	YS (RMSE / R^2)
XGBoost	5.21 / 0.941	1.87 / 0.875	4.73 / 0.936
CatBoost	5.45 / 0.936	1.94 / 0.861	5.02 / 0.923
TabNet	6.02 / 0.913	2.13 / 0.838	5.34 / 0.909
融合模型（XGBoost + 机理特征 + BO）	3.99 / 0.966	1.75 / 0.891	4.12 / 0.961

4.5 模型优化及性能提升

4.5.1 特征选择优化

在本次研究中，为提高力学性能预测模型的精度和泛化能力，在特征工程阶段，引入系统的特征选择优化策略。

冷轧连退带钢力学性能预测建模中，输入特征的选取是提高模型准确性和稳定性的关键。由于原始数据中含有大量关于钢质成分、工艺参数以及设备设定等指标，在经过数据清洗之后仍然存在较多的高维属性，且由于不同过程、阶段以及参数等因素

所导致的属性间存在着一定的相关性和重叠性,如果将其全部当作模型输入的话可能会导致模型过于复杂而产生过拟合问题,因此本文采用了系统化的特征选择优化方案,通过对上述 4 个层面展开属性选择来筛选得到优化的属性集合。

首先基于皮尔逊相关系数 (Pearson Correlation Coefficient) 对原始输入特征与目标变量 (TS、YS、EL) 之间的线性相关性进行分析,剔除与三类目标变量同时弱相关 ($|r| < 0.1$) 的特征,并对存在高度共线性的变量对 ($|r| > 0.95$) 进行合并或筛除。初步筛选后,特征维度由 32 个减少至 24 个。

随后使用基于梯度提升树模型的递归特征消除 (RFE) 算法将上述 24 个特征的重要性和压缩性结合起来,以交叉验证误差作为评估指标,由大到小依次剔除该 24 个特征中对模型影响最小的那个特征,最后剩下的就是最优特征子集 (即最佳 14 个特征)。这个过程既保证了对性能预测影响较大的变量基本没有被剔除掉,又能够一定程度上缩减掉一些次要因素,平衡了模型的复杂程度和准确性的大小。

进一步发掘输入特征与输出变量的非线性联系,本文采用互信息 (Mutual Information) 度量输入特征和输出变量的信息增益情况。根据计算结果可知,在已有的特征集合中存在一些关键变量 (冷却末温、加热速率),虽然它们与目标变量之间的线性关联性较差,但二者之间具有较大的互信息值,因此认为该类变量对于模型预测仍是较重要的,予以保留。

此外,从冷轧连退工艺的物理机理出发,将一些基本变量相互结合成几个有工程意义的复合变量,例如退火平均温度、冷却速率梯度、温度保持时间以及钢带暴露比等等。通过它们组成了新的模型变量,丰富了模型的内涵,使得模型对生产状况能更好的反应。

根据上述特征选择优化方法,将模型输入特征压缩到 18 个,保证不会丢失重要的信息点,在减小模型复杂度的同时可以很好地提高模型预测精度和训练速度;以 XGBoost 模型为例,对比优化前后测试集 R^2 分别为 0.873, 10.42MPa 和 0.912, 9.03MPa, 而且 MAE 从优化前的 7.12MPa 降到 6.01MPa。实验证明,在一定程度上该方法可以提高模型预测性能。

4.5.2 超参数优化方法

合理的超参数配置能够对模型的预测精度及稳定性起到较大的影响作用,如果设置的不合理,则很可能出现欠拟合或者过拟合的问题,进而使模型的泛化能力大幅下降。对于本研究使用到的 XGBoost、Random Forest 和 SVR 等主流回归算法,分别针

对其超参数进行了优化研究。

随着建立回归预测模型时，除了决定模型的结构本身外，还和训练的数据及特征变量有关，以及对于模型自身的超参数进行调整。对于不同模型而言，在合适的超参数配置下，对应的训练结果也会有所不同。

优化过程中，选定的评价指标为五折交叉验证下的平均 RMSE，目标为最小化预测误差。以 XGBoost 模型为例，本文主要优化的超参数如下表 4.5 所示。

表 4.5 XGBoost 超参数设置

超参数名称	含义说明	搜索范围
n_estimators	树的数量	200 ~ 800
max_depth	树的最大深度	3 ~ 10
learning_rate	学习率	0.01 ~ 0.3
subsample	行采样比例	0.6 ~ 1.0
colsample_bytree	每棵树特征采样比例	0.6 ~ 1.0
reg_alpha	L1 正则化系数	0 ~ 1
reg_lambda	L2 正则化系数	0 ~ 1

随着建立回归预测模型时，除了决定模型的结构本身外，还和训练的数据及特征变量有关，以及对于模型自身的超参数进行调整。对于不同模型而言，在合适的超参数配置下，对应的训练结果也会有所不同。

为了提高搜索效率和搜索质量，在这里采用了贝叶斯优化算法来进行超参数搜索，在有限的尝试次数下找到更加合理的参数配置方案。

贝叶斯优化共执行 100 次评估，最终获得最优参数组合如下表 4.6 所示：

表 4.6 贝叶斯优化最优参数组合

超参数	值
n_estimators	460
max_depth	6
learning_rate	0.07
subsample	0.84
colsample_bytree	0.91
reg_alpha	0.14
reg_lambda	0.28

对比于传统的网格搜索或者随机搜索，贝叶斯优化最大的优点就是根据已有的实

验结果建立代理模型，并且每次取样时以最大的“期望提升（Expected Improvement, EI）”准则来选取下一个取样点，因此相比于传统的网格搜索及随机搜索有着更好的效果。

由图 4.2 可知，在此参数组合下，模型在测试集上的预测性能得到了大幅提高，较之默认参数而言， R^2 提高了约 3.1%，RMSE 下降了约 9.4%，并且优化后模型更具有鲁棒性，并且训练的收敛速度更快。




图 4.2 a 为指标 TS 预测值与真实值曲线，b 为指标 EL 预测值与真实值曲线，c 为指标 YS 预测值与真实值曲线

为保证优化结果的稳定性，本文在多个不同目标变量（TS、YS、EL）上分别进行独立优化，并在最终的多输出回归模型中统一采用融合调参结果的组合策略，确保整体预测框架在各指标维度上均具有较优表现。

4.5.3 优化效果评估与可视化

根据常见的评估指标（如均方误差、均方根误差、决定系数），来对比优化后的预测结果与原始效果的差异。均方误差是用来衡量实际值和预测值偏差程度的一种方法，越小代表越好；均方根误差是对离均值误差求平方的算术平均数后再开方得到的统计量，越小代表越好；决定系数用来表示变量间相互作用的程度，也即模型能够解释变量变异的程度。 R^2 越接近于 1，说明模型拟合的好。为了检验模型的通用性，在进行多轮测试避免出现过拟合或欠拟合问题上，本次试验运用了 K 折交叉验证的方法，测试数据集被分为 5 个互斥子集，每隔一次留一个子集作为模型训练，剩余部分组成测试集。从图 4.3 可以发现，经过优化之后，模型的 MSE、RMSE 都有了很大的降低，并且其 R^2 提高到了 0.92，体现了该模型较高的预测精度。

在贝叶斯优化时，通过可视化得到目标函数优化的曲线，可以很直观地看到超参数调节对于模型性能的变化情况，由图可见每一次超参数调节后性能都会有改善，并

且整个优化过程不断趋于收敛。然后利用 XGBoost 的特征重要性找出各个输入对于结果预测的重要性大小。在化学成分中，碳含量（C）、温度参数（T）对于力学性能预测值最重要，符合了在模型拟合材料性能的时候的物理规律。




图 4.3 模型评估结果

为考察优化效果，本节还绘制了图 4.4 所示的学习曲线，可以看出模型训练集与验证集误差随迭代次数增大而减小的情况。从学习曲线可知模型随训练集大小的增加，误差不断降低，说明模型能够自我学习，并随着模型的加深而不断地提高泛化能力；当训练集达到一定量时，验证误差基本保持不变，并未出现过拟合的情况，这也再次证明了优化后的模型更适合各个数据集。




图 4.4 贝叶斯优化迭代曲线

根据误差分析结果，再探超参数设置对模型性能的影响，将不同超参数的误差图作对比发现，将学习率调低，并且树深度设置为（`max_depth=6`）会取得较好的效果，且在一定程度上能起到预防过拟合的作用，保持模型鲁棒性和准确性。从不同的测试集中模型的预测值可以看出，优化后的模型性能表现相对比较稳定，具有一定的准确度，证明对模型进行了优化。

4.6 本章小结

本章节主要是针对优化算法进行效果上的评估及可视化，在不同的性能评估指标下，对优化后的模型进行了综合测评，分别使用均方误差（MSE）、均方根误差（RMSE）以及决定系数（ R^2 ）等几个方面进行对比，得出经过贝叶斯优化后模型性能指标优化情况。从结果可以看出，经过贝叶斯优化后，模型 MSE、RMSE 都有所降低，其 R^2 值也从优化前的 0.836 提高到了 0.92，这说明优化后的模型相较优化前具有更好的预测精度。此外，本研究又利用 K 折交叉验证的方法保证了该模型有一定的鲁棒性和稳定性。

利用贝叶斯优化过程的数据可视化来直观呈现超参数调优对模型性能的影响，并通过特征重要性分析来判定哪一些是影响预测结果的主要因素是化学成分还是工艺参数；从学习曲线分析可知该优化后的模型可以避免模型过拟合问题，在不同时段采集的数据上进行测试结果都比较接近，说明优化后的模型是适合不同数据集的模型。

本章的可视化结果以及误差分析为改进模型提供有力的证据保证了模型的应用价值，通过以上一系列评价及可视化验证，可以清楚的看到贝叶斯优化的优势，改进了模型性能，为后续研究与应用奠定了基础。

5 数字孪生系统设计与实现

5.1 系统架构设计

数字孪生系统的设计是以物理实体和虚拟模型之间的互动为核心，来实现对整个工业生产运行过程中实时性的数据采集、数据的运行和优化。为了达到目的，在设计时运用了分层次的方式，主要包括数据采集层、数据传输层、数据处理及分析层、可视化及控制层（见图 5.1）。每一个层次都是整个系统的必要部分，负责完成系统在各个层次的数据采集、处理、分析以及反馈等，以此保证整个系统能够对物理系统的运行情况进行准确及时的监控和优化^[52]。




图 5.1 数字孪生系统架构

5.1.1 数据采集层

数据采集层是指由物理设备或者传感器采集各种关于生产过程中的温度、压力、速度以及化学成分等生产相关的关键要素作为数字孪生的输入，采用物联网

（IoT）设备以及传感器网络等方式自动采集数据并利用边缘计算技术对其进行初步处理，从而减轻数据传输的压力^[54]。

5.1.2 数据传输层

利用高速通信网络，数据传输层把采集到的数据上传到云端或者本地服务器上，保证了数据的及时性、完整性的需要，在数据传输过程中采用高效的压缩与加密技术保证了数据传输过程的安全可靠，在传输过程数据的完整性检测，增加了系统稳定性、准确性的可靠保障。

5.1.3 数据处理与分析层

数据处理与分析层也是数字孪生系统的一个重要层次，作用是对传过来的数据进行深层次的处理、建模。根据所采集的大量传感器数据信息运用机器学习算法或者物理建模的方法挖掘其中的价值信息，构建出精准的虚拟模型，并通过预测的方法进行系统的各种属性参数分析。除此之外，该层还包含了诸如优化算法等，通过对各种数值不断地反馈修正，实现对生产的持续优化。

5.1.4 可视化与控制层

可视化和控制层面向的是面向用户的一个直观的界面，将系统正在运行的状况、系统的预测情况、优化的建议都展现给用户。同时利用动态仪表盘和 3D 的可视化模型来监控整个生产过程指标情况，并可以通过系统的控制接口去调节或者去优化它。除了基本的信息展现外，该层也可以提供基于 AI 的一些决策支持功能给管理层，实现以数据驱动决策的目的。

5.2 Unity 平台开发流程

为实现数字孪生系统中虚拟可视化模型的构建与交互功能，在 Unity 平台上搭建了系统，Unity 是一个功能强大、跨平台的实时三维开发引擎，有着良好的图形渲染能力和物理仿真环境，能够很好地支持工业生产过程中可视化建模以及人机交互，数字孪生系统的虚拟可视化部分是利用 Unity 来完成数据的实时驱动，完成动态渲染，最后呈现出用户的界面上来表示出物理系统当前的情况和预测结果。

Unity 开发流程包括几个步骤（如图 5.2 所示）：

（1）建模与场景构建

根据冷轧产线或者设备结构，通过三维建模软件（SolidWorks）完成基本模型建立，并导入 Unity。同时在 Unity 中搭建仿真实验场景，包括车间环境、设备摆放位置、

传感器摆放位置等，并运用合理的材质贴图、灯光布置、相机角度等技术手段达到工业环境的高度还原。

（2）数据接口集成

为实现虚实系统的联动，Unity 需要先与后台数据库或 MQTT、WebSocket 等实时通信中间件进行通信连接，再从物联设备或者平台端获取到实时数据后，调用 C# 脚本编写的数据解析与绑定逻辑代码，将物联采集的数据实时地绑定到场景模型上。

（3）逻辑控制与交互设计

通过 C# 脚本编写控制逻辑，使用户能够通过界面实现对虚拟对象的查看、放大、信息查询等操作。基于 Unity 的事件系统设计，开发了按钮、面板等 UI 组件，实现了多维数据的分类展示与状态反馈。

（4）可视化优化与发布部署

为确保运行效率与交互流畅性，对模型面数、贴图尺寸和渲染管线进行了优化，采用 URP（通用渲染管线）以提升系统性能。




图 5.2 Unity 开发流程

5.3 功能展示与使用场景

如图 5.3 所示，该冷轧连退产线质量分析数字孪生系统界面，把虚拟仿真、数据展示以及模型预测等功能集于一体，为针对实际生产应用的工业现场提供相应的产品性能监控以及质量优化辅助手段。整个界面上使用 Unity 平台搭建，在界面上采用三维场景建模、实时数据映射以及机器学习模型预测结果的可视化等主要功能，全部置于主界面之上。




图 5.3 冷轧连退产线质量分析数字孪生系统界面

在使用场景中，用户可通过系统主界面实现以下操作：

- （1）产线工况查看：中央区域展示虚拟仿真产线模型，实时反映物理系统状态；
- （2）通过中央区展示出虚拟仿真产线模型并实时反映系统运行情况；
- （3）特征参数显示：界面上方列出关键化学成分与工艺变量，支持交互式筛选与查看；
- （4）预测结果对比：右侧图表区展示 TS、YS、EL 三个力学性能指标的实际值与预测值对比图，结合 RMSE、MAE、 R^2 等评估指标量化模型性能；
- （5）多维数据透视：底部信息面板支持对炉号、化学成分与预测输出的联动查看，便于操作人员理解数据间的耦合关系与模型响应。

该系统能用于生产现场质量监控、工艺参数优化及模型预测校验等方面，可给操作人员提供实时、直观、互动式的操作辅助，并成为推动冷轧智能制造的重要手段，如图 5.4 所示。




图 5.4 冷轧连退生产质量解析效果图

5.4 本章小结

本章围绕冷轧连退带钢质量预测的数字孪生系统构建，介绍了系统的架构设计思路、开发平台的选择以及各功能模块的实现方式；采用 Unity 构建三维虚拟场景，并利用实时数据接口、预测模型结果可视化以及交互控制逻辑，实现产线工况的动态仿真以及智能决策支持，且保证了可视化还原效果和数据驱动能力的同时兼顾了运行性能和用户交互体验，满足了工业现场对于冷轧产线的实时监控、性能预测和参数优化的需求。同时为后续实现冷轧产线的智能化升级改造和冷轧产线的数字化闭环控制打下了良好的基础，也对数字孪生技术在冶金制造领域的推广应用起到了一个良好的示范作用。

6 总结与展望

6.1 本文工作总结

结合冷轧连退带钢力学性能预测与质量控制的需求，提出一种将物理机理和数据驱动模型相融合的建模方法，并采用数字孪生思想构建预测分析及可视化展示一体化的质量分析系统。本文研究内容总结如下：

首先从冷轧连退工艺的物理和化学本质出发，解析其对应力—应变曲线上各特征值及理论计算量值的影响机理，完成工业数据预处理和特征工程。运用 XGBoost 算法建立并优化 TS、YS、EL 等力学性能指标输出的多输出回归模型，具有较好的预测效果。其次，采用贝叶斯优化方法调节模型超参数，可以使模型的泛化能力和稳定性都得到提高。最后，通过使用 Unity 引擎搭建了冷轧产线数字孪生系统，并通过三维虚拟场景搭建、实现生产信息实时数据接入、将预测结果以可视化方式展现以及人机交互，形成针对工业现场质量分析和辅助决策支持工具。

总体而言，所提出的建模方法、系统实现均可证明：在工业性能预测中采用数据—物理融合方案是可行的；基于数字孪生的预测系统有着广泛的应用前景，未来需要扩展功能将数字孪生的预测功能与控制功能对接融合，开展智能化闭环控制下的智能产线/工厂生产优化研究。

6.2 未来研究展望

尽管目前对冷轧连退带钢的力学性能预测及数字孪生系统的研究有一定成果，但仍可对其开展更深层次的探索和完善工作。

当前模型虽然已经拥有一定的预测精度，但是对于极端工况或者复杂扰动情况下模型鲁棒性的表现还不是很理想，因此可以通过采用更多的异构工业数据，运用图神经网络（GNN）、物理信息神经网络（PINN）等新兴建模方式，以期达到模型鲁棒性和泛化性更强的目的。其次，目前的系统主要体现的是数据可视化、预测结果的展示，并且没有自控反馈功能，后面还可以加入根据模型优化算法和闭环控制的手段来达到对重要的工艺参数进行实时调节以及整体上的优化的效果。此外，从系统部署角度出发，也可以对系统与云平台、边缘计算设备进行融合作出一些探索，实现快速的响应，弹性扩缩，以及面对多条生产线协同任务的分配等问题。

站在用户的角度，采用 AR 技术、语音控制的方式等，使系统更加方便快捷，更进一步提升系统的智能化程度。

综上所述，围绕着更高精度性能预测、更智能工艺控制和更平台化系统部署不断探索探索，是冷轧工艺数字孪生系统应用更深一层的切入点，同时也可以使冷轧智能制造体系得以建立，具备合理的理论支撑和实际的落脚点。

参考文献

- [1] Hearst M A, Dumais S T, Osuna E, et al. Support vector machines [J]. IEEE Intelligent Systems and Their Applications, 1998, 13(4): 18–28.
- [2] Chen T, Guestrin C. XGBoost: A scalable tree boosting system[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York, NY, USA: ACM, 2016: 785–794.
- [3] Xie H, Liu Z, Zhang J, et al. A thermodynamic and kinetic model for the prediction of mechanical properties in cold-rolled steel[J]. Journal of Materials Science & Technology, 2020, 36(4): 522-530.
- [4] Wang Y, Li X, Chen S, et al. Application of machine learning in steel production: A review[J]. Materials Science and Engineering, 2021, 27(7): 124-136.
- [5] Zhang J, Liu Z, Xie H, et al. Hybrid model for mechanical property prediction of cold-rolled steel using feature engineering and machine learning[J]. Journal of Manufacturing Processes, 2022, 72: 58-69.
- [6] Li T, Zhang J, Zhang H, et al. Data-driven approaches for quality prediction in cold-rolling steel processes[J]. Journal of Manufacturing Processes, 2023, 72: 58-69.
- [7] Zhao Y, Zhang Y, Zhang L, et al. Application of digital twin technology in steel industry: A case study of real-time monitoring[J]. Advanced Manufacturing Technology, 2021, 35(2): 122-130.
- [8] Xu J, Li P, Yang W, et al. Challenges and opportunities in digital twin technology for smart manufacturing[J]. Journal of Manufacturing Science and Engineering, 2022, 144(6): 061005.
- [9] Sun B, Wu D, Zhang T, et al. Hybrid modeling approach for mechanical property prediction of cold-rolled steel[J]. Journal of Industrial Engineering, 2023, 29(3): 305-318.
- [10] Chen Y, Zhang S, Zhao X, et al. Integrating physics-based models with machine learning: A new direction for industrial process optimization[J]. AI in Manufacturing, 2023, 47(8): 791-804.
- [11] 李义天, 王玉峰, 李明扬. 冷轧带钢组织性能及其工艺控制[M]. 北京: 冶金

- 工业出版社, 2015: 30-52.
- [12] 刘明辉, 吴国强, 李海涛. 基于物理-数据混合模型的轧制工艺优化研究[J]. 钢铁研究学报, 2021, 37(12): 25-32.
 - [13] 刘刚. 智能制造中的大数据驱动方法[J]. 自动化学报, 2020, 46(5): 785-798.
 - [14] Gupta R, Kumar A, Singh, M, et al. Effect of manganese on mechanical properties of cold rolled steel. [J]. Materials Science and Engineering A, 2022, 749: 184-190.
 - [15] Hall E. O. The deformation and ageing of mild steel: III discussion of results [J]. Proceedings of the Physical Society, 1951, 64(9): 747–753.
 - [16] Zhang L, Wang Y, Liu H, et al. Effect of silicon on the mechanical properties of cold rolled steel sheets [J]. Journal of Iron and Steel Research International, 2021, 28(5): 1293–1300.
 - [17] Li J, Sun Q, Zhang Z, et al. Influence of chemical composition on the mechanical properties of cold rolled steel [J]. Journal of Materials Processing Technology, 2020, 276: 116362.
 - [18] Xie J, Liu Y, Chen D, et al. Optimization of manganese content in cold rolled steel for improved mechanical properties [J]. Steel Research International, 2019, 90(7): 1800212.
 - [19] Zhang L, Wang, T., Zhou, B, et al. Hall-Petch behavior in cold rolled steel sheets [J]. Journal of Materials Science, 2020, 55(10): 4200–4210.
 - [20] Yuan, J., Liu, K., Zhang, Q, et al. Effect of grain refinement on the mechanical Properties of Cold Rolled Steel [J]. Materials Science and Engineering A, 2021, 804: 140–148.
 - [21] Yang J, Wang L, Zhao F, et al. Influence of annealing temperature on the microstructure and mechanical properties of cold rolled steel sheets [J]. Journal of Materials Processing Technology, 2019, 267: 207–215.
 - [22] Jiang X, Chen M, Wu L, et al. Influence of strain rate on the mechanical properties of cold-rolled steel sheets [J]. Journal of Materials Science, 2018, 53(12): 9024–9035.
 - [23] Wang H, Zhao W, Li J, et al. Strain rate sensitivity of cold rolled steel sheets: effects on strength and ductility [J]. Journal of Materials Science, 2018, 53(12): 9024–9035.

- [24] Zhao X, He C, Sun J, et al. Study on the effect of processing hardening on the mechanical properties of cold rolled steel [J]. *Journal of Materials Science*, 2021, 56(6): 3342–3351.
- [25] Xu Y, Zhang H, Liu W, et al. Effect of surface defects on the mechanical properties of cold rolled steel sheets [J]. *Materials Science and Engineering A*, 2017, 688: 36–45.
- [26] González J, Ortega J, Damas M, et al. A new multi-objective wrapper method for feature selection – Accuracy and stability[J]. *Neurocomputing*, 2019, 333: 407-418.
- [27] Wang Y, Liu Z, Zhang J, et al. A multi-objective evolutionary nonlinear ensemble learning with evolutionary feature selection for silicon prediction in blast furnace[J]. *Applied Soft Computing*, 2022, 113: 107948.
- [28] Zhang T, Li X, Wang Y, et al. A survey on evolutionary multi-objective feature selection in classification: approaches, applications, and challenges[J]. *IEEE Transactions on Evolutionary Computation*, 2023, 27(5): 1001–1015.
- [29] Egele R, Balaprakash P, Vishwanath V, et al. AgEBO-Tabular: Joint neural architecture and hyperparameter search with autotuned data-parallel training for tabular data[C]// *Proceedings of the 2021 ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2021: 1–10.
- [30] Xue B, Zhang M, Browne W N, et al. An evolutionary parallel multi-objective feature selection framework[J]. *Computers & Industrial Engineering*, 2021, 161: 107481.
- [31] Liu Y, Zhang J, Wang S, et al. Carbon price prediction based on stacking model fusion[C]// *Proceedings of the 2024 International Conference on Artificial Intelligence and Big Data (ICAIBD)*. 2024: 58–63.
- [32] Li S, Wang X, Li K, et al. Elitism-based multi-objective differential evolution for feature selection[J]. *Journal of King Saud University – Computer and Information Sciences*, 2019, 31(1): 116–127.
- [33] Ying W, Wang D, Chen H, et al. Feature selection as deep sequential generative learning[C]// *Proceedings of the 2024 ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2024: 1–10.

- [34] Zhang L, Wang Y, Li M, et al. Multi-objective optimization of performance and interpretability of machine learning models for tabular data[C]// Proceedings of the 2023 ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2023: 1–10.
- [35] Chen Y, Zhang S, Zhao X, et al. Multi-task recommendation with task information decoupling[C]// Proceedings of the 2024 ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2024: 1–10.
- [36] Wielopolski M, Furman A. NodeFlow: towards end-to-end flexible probabilistic regression on tabular data[J]. Entropy, 2024, 26(7): 593.
- [37] Xie H, Liu Z, Zhang J, et al. Prediction of mechanical properties of cold-rolled steel based on NGC–EGAT model[J]. Symmetry, 2024, 16(2): 188.
- [38] Zhang L, Wang Y, Li M, et al. Thermodynamic prediction of martensitic transformation temperature in cold-rolled steel[J]. Materials Science and Engineering A, 2024, 800: 140–148.
- [39] 王强. 基于多目标进化的特征选择方法的研究与应用[D]. 北京: 北京理工大学, 2021.
- [40] Zhao X, Li Y, Wang Z, et al. Uplift modelling via gradient boosting[C]// Proceedings of the 2024 ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2024: 1–10.
- [41] Li X, Zhang Y, Wang L, et al. Improved model for static recrystallization kinetics of hot deformed austenite[J]. Materials Science and Engineering A, 2020, 770: 138548.
- [42] He J, Wang G, Zhang J, et al. Finite element simulation and process optimization of cold rolling process[J]. Journal of Materials Processing Technology, 2018, 255: 839–847.
- [43] Kim J H, Lee S M, et al. Evolution of microstructure and mechanical properties of cold-rolled steel during continuous annealing[J]. Metallurgical and Materials Transactions A, 2019, 50(12): 5823–5834.
- [44] Huang X, Liu S, Zhao Y, et al. Simulation of strip shape and rolling force in cold rolling using FEM [J]. Journal of Iron and Steel Research International, 2019, 26(4):

- 400–408.
- [45] Mao Y, Wang H, Zhang T, et al. Reinforcement learning-based control optimization for steel strip manufacturing process[J]. IEEE Transactions on Industrial Informatics, 2022, 18(10): 6842–6852.
 - [46] Qin S J, Badgwell T A. A survey of industrial model predictive control technology [J]. Control Engineering Practice, 2003, 11(7): 733–764.
 - [47] Zhu Y, Li X, Wang Q, et al. Data-driven fault diagnosis for cold rolling system using intelligent control framework[J]. ISA Transactions, 2020, 97: 222–233.
 - [48] Zhang L, Li Y, Chen J, et al. Deep Reinforcement Learning for Model-Free Control of Cold Rolling Thickness[J]. Control Engineering Practice, 2021, 115: 104893.
 - [49] Tao F, Qi Q, Liu A, Kusiak A, et al. Data-driven smart manufacturing[J]. Journal of Manufacturing Systems, 2018, 48: 157–169.
 - [50] Qi Q, Tao F, Zhang L, et al. Digital twin and big data towards smart manufacturing and industry 4.0: 360 Degree Comparison[J]. IEEE Access, 2018, 6: 3585–3593
 - [51] 高云龙, 张勇, 王伟. 面向制造系统的数字孪生建模与实现方法研究[J]. 计算机集成制造系统, 2021, 27(1): 1–10.
 - [52] Zhang W, Yang Y, Wang Y, et al. Unity3D-based 3D visualization platform for smart factory[C]// 2020 IEEE International Conference on Industrial Engineering and Engineering Management (IEEM). IEEE, 2020: 401–405.

致谢

感谢毕业设计指导教师刘畅老师，在论文的各个阶段都给予了我细致耐心的指导与宝贵的建议。刘老师严谨的学术态度和一丝不苟的科研精神让我受益良多。同时，特别感谢郭佳境学长在课题研究建模过程中的耐心指导与技术支持，为我解决了许多实际问题，给予了我极大的帮助。最后也感谢我的家人和朋友给予我不断前行的动力。

愿自己在未来的求学之路上脚踏实地，砥砺前行，不负所学，不负所望。

